Strategies de chunking pour les pipelines RAG

Le choix d'une strategie de chunking influence directement la qualite de la recherche a posteriori. Un decoupage a taille fixe est rapide a calculer et independant du format d'entree, mais il ignore la structure du document et peut couper une idee en deux morceaux distincts.

Un decoupage recursif tente de respecter les frontieres naturelles du texte, comme les paragraphes ou les phrases, avant de retomber sur un decoupage plus brutal si un segment reste trop volumineux. Cette approche convient bien aux documents structures comme des rapports ou de la documentation technique.

Un decoupage semantique va plus loin en regroupant les phrases selon leur proximite de sens, calculee a partir de leurs embeddings, ce qui produit des chunks thematiquement coherents meme lorsque la mise en forme d'origine ne l'indique pas clairement. Cette methode est particulierement utile pour du texte scrape ou une transcription mal structuree.